EDA262 · ENGENHARIA DE DADOS · PARTE 2 (AV2)

Das vulnerabilidades já exploradas, quais continuam com alta chance de serem exploradas de novo?

O lake da Parte 1 ganhou volume real (EPSS), três camadas, Parquet particionado, carga idempotente e incremental e acesso por camada no Lake Formation — e responde por US$ 0,00004768.

Grupo g07 · CESAR School · 2026.2

Bruno Ribeiro · Emanuel Eduardo · Igor Alves · Leonardo Amaral · Victor Guilherme · Vinícius Petribu

Por que o EPSS: a Parte 1 ficou abaixo do piso de cobrança

- O Athena cobra no mínimo **10 MB** por consulta. O KEV inteiro tem **1,5 MB**: Parquet e partição sobre ele economizariam **US$ 0,00**.
- **EPSS** (FIRST): a probabilidade de cada CVE ser explorada nos próximos 30 dias, publicada **todo dia** para **~384 mil** CVEs.
- O cruzamento traz **informação**, não só volume: entre as já exploradas, separa as que continuam perigosas agora.

> **Nossa pergunta:** quais fabricantes concentram as CVEs exploradas do último ano — e qual a chance de exploração do portfólio explorado de cada um?

80,9 MB

30 dias de EPSS (gzip) — acima do piso

11,5 mi

linhas na janela de 30 dias

0,49 vs 0,0065

EPSS mediano: CVEs do KEV vs todas (76×)

Arquitetura: três camadas, tudo em código

1

Coletar

KEV e EPSS, por backfill ou carga incremental.

ingest_kev.sh · ingest_epss.sh

›

2

Raw

Os bytes como foram publicados.

CSV gzip + JSON · partition projection

›

3

Trusted

Validado e tipado, com grão garantido.

Parquet ZSTD · partição diária

›

4

Refined

A resposta pronta: fabricante × dia.

Parquet ZSTD · fabricante × dia

> **Terraform** em 2 módulos (data-lake, governance) · **Lake Formation** por camada · transformações em **SQL no Athena** · workspace **av2** · **73 recursos** num apply do zero.

Partição e idempotência, medidas na AWS

PARTIÇÃO DIÁRIA (SNAPSHOT_DATE)

29×

menos bytes numa consulta de 1 dia: **779.638 B** contra **22.606.275 B** dos 30 dias.

- Grão **(cve_id, dia)**: **0** duplicadas em 11.519.635 linhas.
- Point-in-time: **37** CVEs contadas no dia certo.

CARGA IDEMPOTENTE E INCREMENTAL

391.915

linhas antes e depois de recarregar 20/10. Só acrescentar daria **783.830**.

- Backfill de **30** dias num único INSERT: leu a raw **uma vez só** (80,9 MB).
- Incremental pela marca d'água de cada camada.

Quem lê cada camada: decidido pelo Lake Formation

PERFIL	RAW	TRUSTED	REFINED
data-engineer	lê	lê	lê
data-analyst	negado	lê	lê
business-user	negado	negado	lê

Teste ao vivo: cada perfil assumido, cada camada consultada. **9 de 9** iguais à matriz declarada. Negação real: *“Insufficient Lake Formation permission(s): Required Describe on eda262_g07_raw”*.

- IAM **idêntico** nos 3 perfis: a negação só pode vir do Lake Formation.
- **0** permissões S3 nos buckets do lake.
- Padrão **IAMAllowedPrincipals removido**: sem isso, os grants seriam decorativos.
- Um WorkGroup por perfil: resultados e histórico isolados.

A resposta: volume ainda não é risco



Ranking pelas CVEs exploradas adicionadas ao KEV nos 12 meses até 20/10/2026. EPSS médio de todas as CVEs exploradas de cada fabricante, no último dia da janela de 30 dias.

CHANCE DE EXPLORAÇÃO

0,82 vs 0,13

Ivanti (6 novas) · Apple (10 novas)

A Ivanti é só a 8ª em volume, mas o portfólio explorado dela tem a maior chance de exploração do ranking — 6× a da Apple.

Meta de custo declarada e cumprida

US$ 0,00004768

por consulta: **162.943 B** lidos de no máximo 10.485.760 — **64×** abaixo da meta

A MESMA PERGUNTA, POR CAMADA (BYTES LIDOS)



As três respostas saíram **idênticas, byte a byte**.

- Refined lê **505×** menos que a raw; o custo cai **7,9×**, porque o piso de 10 MB limita.
- O Parquet do Athena ficou **13% maior** que o CSV e mesmo assim leu **1,45×** menos: custo é o que se lê.
- Medido, não estimado: a estimativa local errou, e corrigimos.

Demonstração: execução real na AWS

1 apply do zero no workspace av2

```
Apply complete! Resources: 73 added, 0 changed, 0 destroyed.
  OK Workspace          : av2
  OK Pipeline WorkGroup : eda262-g07-wg
  OK persona data-analyst:
     eda262-g07-wg-data-analyst reads trusted, refined
```

2 backfill de 30 dias pelas três camadas

```
==> EPSS range 2026-09-21 .. 2026-10-20: 30 day(s)
  OK 30 file(s) passed the header, date and
     integrity gates
  OK trusted: every day landed with its source
     row count, 1 model version and 0 duplicate keys
  OK refined: 30 day(s), one row per vendor per day
```

3 consulta com custo medido, nas três camadas

```
  raw      82325456 bytes scanned  -> USD 0.00037437
  trusted  56913236 bytes scanned  -> USD 0.00025881
  refined  162943 bytes scanned  -> USD 0.00004768
  answers identical across layers: true
  OK cost target met: 162943 bytes scanned
     <= 10485760 (USD 0.00004768)
```

4 idempotência e verifica.sh

```
  trusted.epss_scores
    rows 391915 -> 391915  (append-only would give 783830)
  refined.vendor_exposure_daily
    rows 290 -> 290  (append-only would give 580)

Resultado: 37 PASSA / 2 FALHA  (total: 39 criterios)
```

Cada decisão, um número

DECISÃO	NÚMERO QUE A SUSTENTA
Grão (cve_id, dia)	**0 duplicadas em 11,5 mi**
Partição diária	**29× menos bytes (1 dia)**
Parquet + ZSTD	**1,45× menos lido**
Refined pré-agregada	**162.943 B · 64× abaixo da meta**
Sobrescrita de partição	**391.915 → 391.915**
Lake Formation por camada	**9 de 9 combinações**

DO PROJETO AO PRODUTO

Priorizar correção por **risco real**: já explorada (KEV) e com chance alta de exploração agora (EPSS), atualizado todo dia por **US$ 0,0003**.

ENGENHARIA QUE ESCALA

- SQL no Athena: **40×** mais barato que um job Glue.
- Carga diária incremental, sem duplicar nada.

Repositório: github.com/brunoribeirol/eda262-projeto-g07
Todas as decisões: DECISOES.md